

TECHNICAL PROPOSAL v1.0

AI体育动作智能评估系统 技术方案

基于计算机视觉与深度学习的运动分析解决方案

文档版本

v1.0

编写日期

2026-02-09

适用范围

体育教育、健身训练、考试评测

目录

01 项目概述

项目背景、目标与支持的6种基础运动类型

03 核心技术原理

姿态表示、ST-GCN、时序U-Net、多任务学习

05 评估体系设计

四维度评分体系与模型评估指标体系

07 应用场景

学校体育、健身行业、运动员训练、医疗康复

02 系统架构

三层架构设计与五大核心模块功能说明

04 数据处理流程

视频解码、姿态检测、时序对齐、特征标准化

06 部署方案

云端/边缘端/移动端三种部署模式与优化策略

08 实施计划与风险

三阶段实施规划与风险识别应对策略

1. PROJECT OVERVIEW

项目概述

1.1 项目背景

传统体育教学和考试中，动作评估主要依赖教练肉眼观察，存在以下痛点：

- 主观性强**
不同教练评判标准不一致
- 效率低下**
人工逐个指导耗时耗力
- 难以量化**
动作细节难以精确记录和分析
- 反馈滞后**
无法实时给出改进建议

1.3 支持的运动类型

运动类别	具体动作	适用场景
力量训练	俯卧撑、深蹲、仰卧起坐、引体向上	体能训练、体育考试
有氧训练	跳绳	日常锻炼、减肥训练
爆发力训练	跳远	田径考试、运动员选拔

注：系统设计支持快速添加新的运动类型，具有良好的可扩展性。

1.2 项目目标

构建一套基于视觉的体育动作智能评估系统，实现：

- 自动识别**
识别用户进行的体育动作类型
- 实时分析**
实时分析动作执行过程
- 精准评分**
给出客观、量化的动作质量评分
- 错误诊断**
自动检测动作中的错误并给出改进建议
- 个性化指导**
根据用户表现提供针对性训练建议

2. SYSTEM ARCHITECTURE

系统架构

2.1 整体架构



2.2.1 数据采集层

输入源:

手机摄像头（前置/后置）、监控摄像头、专用体测设备、预录视频文件

技术要求:

- 分辨率: 720P 及以上
- 帧率: 25-30 FPS
- 拍摄角度: 正面或侧面（根据动作类型）
- 光照条件: 光线充足, 避免逆光

2.2.3 动作识别模块

功能:

识别用户正在进行的具体动作类型

技术方案: ST-GCN

- 输入: 60 帧的骨骼序列
- 输出: 动作类别概率分布
- 支持类别: 6 种基础运动（可扩展）

2.2.2 姿态检测模块

功能:

从视频帧中提取人体骨骼关键点

技术选型: YOLOv8-Pose

- 检测 17 个 COCO 格式关键点
- 实时性能: > 30 FPS
- 精度: 关键点检测 AP > 70%

输出:

每帧 17 个关键点的坐标 (x, y) 和置信度

2.2.4 阶段分割与质量评估

阶段分割:

时序 U-Net 网络, 将动作过程划分为不同语义阶段（如俯卧撑的准备、下降、最低点、上升、完成）

质量评估:

多任务学习框架, 评估准确性、稳定性、标准性、安全性四个维度, 输出综合评分、错误类型和改进建议

3. CORE TECHNOLOGY

核心技术原理（一）

3.1 人体姿态表示

3.1.1 骨骼关键点定义

采用 COCO 格式的 17 个关键点，覆盖全身主要关节：

头部

鼻子、左眼、右眼、左耳、右耳

躯干

左肩、右肩、左髋、右髋

上肢

左肘、右肘、左腕、右腕

下肢

左膝、右膝、左踝、右踝

3.1.2 特征工程

原始特征：

2D 坐标 (x, y) + 检测置信度

衍生特征：

- 关节角度：肘关节角度、膝关节角度等
- 相对位置：关节间的相对距离和方向
- 时序特征：速度、加速度

特征标准化：

- 以髋部中心为原点
- 以肩宽为单位长度归一化
- 旋转对齐：使肩部连线水平

3.2 动作识别原理

3.2.1 为什么使用图卷积？

人体骨骼天然构成图结构：



传统 CNN 处理规则网格数据（如图像），而 GCN 可直接处理图结构数据，更适合人体姿态分析。

3.2.2 时空图卷积网络 (ST-GCN)

空间维度 (Space)：

通过邻接矩阵定义关节连接关系，图卷积聚合相邻关节信息

$$X' = A \cdot X \cdot W$$

A: 归一化邻接矩阵 | X: 节点特征 | W: 可学习权重

时间维度 (Time)：

使用 1D 卷积提取时序特征，捕捉动作时间演变规律

网络结构：

输入 [T, N, C] $\rightarrow$ ST-GCN Block $\times$ 6 $\rightarrow$ 全局平均池化 $\rightarrow$ 全连接层 $\rightarrow$ 动作类别概率

3. CORE TECHNOLOGY

核心技术原理（二）

3.3 阶段分割原理

3.3.1 问题定义

将时序数据划分为语义上连续的片段，每个片段代表动作的一个阶段。

示例：俯卧撑的阶段

① 准备姿势 → ② 下降过程 → ③ 最低点 → ④ 上升过程 → ⑤ 完成姿势

技术挑战：阶段边界模糊、不同人执行速度不同、阶段时长不平衡

3.3.2 时序 U-Net 架构

借鉴图像分割领域的 U-Net 思想，应用于时序数据：

编码器（下采样）：

逐层提取高级时序特征，使用 MaxPooling 降低时间分辨率，捕捉长时程依赖关系

解码器（上采样）：

恢复原始时间分辨率，Skip Connection 保留细节信息，逐帧输出阶段标签

优势：

能够同时利用全局上下文和局部细节，对边界检测更精确

3.4 质量评估原理

3.4.1 多任务学习框架

质量评估涉及多个相关任务，采用多任务学习架构：

共享特征提取器

- **整体评分头** → 总分 (0-100)
- **维度评分头** → 准确性/稳定性/标准性/安全性
- **错误检测头** → 多标签分类 (20+ 种错误)
- **标准判断头** → 是否标准动作

优势：任务间共享表示提高数据效率，各任务相互促进提升整体性能

3.4.2 规则与模型融合

模型评估：

基于大量标注数据学习，能够捕捉复杂的非线性模式，对未见过的数据有泛化能力

规则评估：

基于运动生物力学原理，可解释性强，对极端情况鲁棒

融合策略：

简单平均：(ModelScore + RuleScore) / 2

置信度加权：根据模型置信度动态调整权重

4. DATA PROCESSING

数据处理流程

4.1 整体流程



4.2.1 姿态检测

使用 YOLOv8-Pose 模型检测每帧的人体关键点。

处理策略：

- 单人场景：取检测置信度最高的人
- 多人场景：默认取第一个人（或选择最大的人）
- 遮挡处理：使用插值填充缺失的关键点

4.2.3 坐标标准化

消除个体差异和拍摄条件影响：

1. 平移归一化：

$$x' = x - x_{hip}, y' = y - y_{hip}$$

以髋部中心为原点

2. 缩放归一化：

$$x'' = x' / w_{shoulder}, y'' = y' / w_{shoulder}$$

以肩宽为单位长度

3. 旋转对齐：

计算肩部连线角度，旋转使肩部连线水平

4.2.2 时序对齐

不同视频长度不一，需要统一到固定长度。

方法：线性插值

- 原始序列：N 帧
- 目标序列：60 帧
- 对每一维特征进行独立插值

平滑处理：

使用 Savitzky-Golay 滤波器平滑插值结果，减少抖动

4.3 数据标注流程

- 1 视频采集
- 2 自动骨骼提取 (YOLO)
- 3 自动标注 (基于规则)
- 4 人工复核 (GUI工具)
- 5 高质量标注数据 → 模型训练

自动标注策略：基于运动生物力学规则自动生成标注，大幅减少人工标注工作量，人工只需复核和修正

5. EVALUATION SYSTEM

评估体系设计

5.1 评分维度

维度	权重	说明	示例指标
准确性	40%	动作是否标准	关节角度、幅度
稳定性	30%	动作是否流畅	速度变化、抖动
标准性	20%	是否符合规范	各阶段是否达标
安全性	10%	是否有受伤风险	错误动作检测

5.2 评分等级

90-100 优秀 动作规范，几乎无瑕疵	80-89 良好 动作较好，有轻微不足
60-79 及格 基本达到要求，有改进空间	0-59 不及格 未达基本要求，需重新学习

5.3 模型评估指标

5.3.1 动作识别

- 准确率 (Accuracy)
分类正确的比例
- 混淆矩阵
各类别的详细识别情况
- F1-Score
综合考虑精确率和召回率

5.3.2 阶段分割

- 帧级准确率
单帧阶段分类准确率
- 边界 F1-Score
阶段边界检测性能
- 编辑距离
预测序列与真实序列的相似度

5.3.3 质量评估

- MAE (平均绝对误差)
与人工评分的差距
- 相关性 (Pearson r)
与人工评分的一致性
- 错误检测准确率
多标签分类性能

6. DEPLOYMENT STRATEGY

部署方案

6.1 部署模式对比

☁️ 云端部署

架构:

用户设备 → 视频流 → 云服务器 → AI推理 → 返回结果

适用场景:

- 学校体育考试
- 健身房团体课程
- 专业运动员训练

优势:

计算能力强、集中管理、数据便于汇总

劣势:

依赖网络、存在传输延迟

🏠 边缘端部署

架构:

摄像头 → 边缘设备(Jetson/NPU) → 本地推理 → 实时反馈

适用场景:

- 家庭健身镜
- 智能体测设备
- 需要实时反馈的场景

优势:

低延迟、不依赖网络、保护隐私

劣势:

计算资源受限、模型需轻量化

📱 移动端部署

架构:

手机摄像头 → 本地APP → 轻量模型推理 → 即时反馈

适用场景:

- 个人健身指导APP
- 家庭自主训练
- 校园体育作业

技术方案:

模型量化(INT8)、知识蒸馏、TensorFlow Lite

6.2.1 模型压缩

量化 (Quantization)

- 将 FP32 权重转换为 INT8
- 模型大小减少 75%
- 推理速度提升 2-4 倍
- 精度损失 < 1%

剪枝 (Pruning)

移除不重要的连接, 减少模型参数量, 配合量化使用效果更佳

知识蒸馏 (Distillation)

大模型(Teacher)指导小模型(Student), 小模型达到接近大模型的性能

6.2.2 推理加速

ONNX Runtime

- 跨平台部署
- 支持 GPU 加速 (CUDA/TensorRT)
- 算子优化

TensorRT

- NVIDIA GPU 专用
- 层融合优化
- 混合精度推理

7. APPLICATION SCENARIOS

应用场景

1 学校体育教育
School Physical Education

痛点：

- 体育老师数量有限，难以逐个指导
- 学生动作不标准容易受伤
- 体育考试评分主观性强

解决方案：

- AI 辅助教学，实时纠正学生动作
- 自动生成个人训练报告
- 标准化考试评分流程

预期效果：

+50%
教学效率

+30%
动作规范性

↑
考试公平性

2 健身行业
Fitness Industry

痛点：

- 私教成本高
- 学员自主训练时缺乏指导
- 训练效果难以量化

解决方案：

- 智能健身镜实时指导
- 生成个性化训练计划
- 记录训练数据，追踪进步

预期效果：

-60%
私教成本

↑
学员留存率

↑
训练科学性

3 运动员训练
Athlete Training

痛点：

- 高水平训练需要精细化分析
- 传统视频分析耗时
- 难以量化技术动作细节

解决方案：

- 高精度动作捕捉和分析
- 对比优秀运动员动作模板
- 量化技术改进效果

预期效果：

+40%
技术改进效率

-25%
伤病风险

4 医疗康复
Medical Rehabilitation

痛点：

- 康复训练需要精确控制动作
- 患者居家训练缺乏监督
- 康复进度难以客观评估

解决方案：

- 康复动作标准化评估
- 远程监督患者训练
- 量化康复进度

预期效果：

↑
康复效果

↓
复诊次数

8. IMPLEMENTATION & RISK

实施计划与风险应对

8.1 阶段划分

1 第一阶段：基础系统搭建

时间：1-2 月
目标：支持 2-3 种动作
产出：准确率 > 85%

2 第二阶段：扩展与优化

时间：3-4 月
目标：支持 6 种动作
产出：准确率 > 90%

3 第三阶段：产品化

时间：5-6 月
目标：部署上线
产出：支持多平台

8.3 风险与应对

技术风险：

- 姿态检测在复杂场景失效
影响：高 | 应对：增加数据多样性，优化检测算法
- 模型泛化能力不足
影响：高 | 应对：数据增强、领域自适应技术
- 边缘设备性能不足
影响：中 | 应对：模型轻量化、模型量化

8.2 数据需求与团队配置

数据需求：

动作类型	最少样本	理想样本
单个动作	500	2000+
整体系统	3000	10000+

数据采集策略：与学校/健身房合作采集、公开数据集补充、数据增强扩充

团队配置：

算法工程师	2 人 模型设计、训练、优化
后端工程师	1 人 推理服务、API 开发
前端工程师	1 人 用户界面开发
产品经理	1 人 需求分析、项目管理
测试工程师	1 人 质量保证、性能测试

业务风险：

- 用户接受度低
影响：高 | 应对：渐进式推广，强调辅助而非替代
- 隐私顾虑
影响：中 | 应对：本地化部署选项，数据加密
- 标注成本高
影响：中 | 应对：自动标注 + 半监督学习

CONCLUSION

技术赋能体育 智能引领未来

AI体育动作智能评估系统将为体育教育、健身训练、专业竞技和医疗康复带来革命性变革



体育教育

教学效率提升50%



健身行业

私教成本降低60%



运动员训练

技术改进效率+40%



医疗康复

量化康复进度

如有任何问题或建议，请联系技术团队

文档版本 v1.0 | 编写日期 2026-02-09